保研推荐系统：夏令营推荐模块

第四小组演示汇报

2026 年 4 月 2 日

目标

推荐用户选择恰当的夏令营进行准备：结合过往经验贴中的入营与背景信息，为每位用户匹配更合适的目标学院夏令营，评估各夏令营入营的门槛与侧重点，助力保研申请决策。

目录

1. 数据预处理
2. 申请者的竞赛/论文/本科层次价值评估
3. 院校夏令营画像
4. 用户画像与推荐
5. 成果展示

数据标准化与向量化

- 校名/院系对齐：用正则 + 别名表（如「浙大」→「浙江大学」），从标题、备注、夏令营详情里抓取「目标学院」；同时保留采集字段里的本科层次（末九、华五等），供后面权重表使用。
- 成绩文本：从 `rank_text`、百分比、名次/总人数等解析成 0–100 的成绩特征（越高表示相对越好）。
- 多热向量：[竞赛获奖、论文发表] 各建一张词表；每条帖子在这些表上各出现过的条目置 1，其余为 0。
- 入营标签：结合结构化字段 `camp_admitted` 与「上岸、offer、优营」、「未入营、被拒」等关键词做入营判定。

向量化 I

Listing 1: 特征提取与向量化

```
def multi_hot(vocab_index: Dict[str, int], values: List[str]) -> List[int]:
    vec = [0] * len(vocab_index)
    for v in values:
        if v in vocab_index:
            vec[vocab_index[v]] = 1
    return vec

for rec in rows:
    comp_display, comp_tags = extract_competitions(rec)
    school_depts = extract_school_departments(rec)
    school_tier_str = rec.get("school_tier") or "未知"
    compact_rows.append({
        "id": rid, "成绩": score_text,
        "本科层次": school_tier_str,
        "入营情况": admission_map
    })
    # 生成特征向量
    vector_rows.append({
        "id": rid,
        "competition_vector": multi_hot(comp_index, comp_tags),
        "school_dept_vector": multi_hot(sd_index, school_depts) })
```

处理前后对比

处理前（原始采集数据）

Raw JSON

- "source_title": " 三本跨保清华..."
- "rank_text": " 前 1%"
- "competition_achievements": [{"name": " 蓝桥杯", "level": " 省一"}]
- "notes": " 最终拿到了清华贵系 offer"

处理后

Compact & Vector

- Compact: id、成绩、本科层次、学校院系、入营情况:{ " 浙江大学-计算机": true, ...}
- Vocab 规模（示例跑批）：竞赛维 50、论文维 60、目标院系 43
- Vector: 三条多热向量，与词表对齐

输出文件：compact.jsonl, vocab.json, vectors.jsonl

评估方式

- 先按夏令营高校（帖子里出现的学校）分组。对该组记：pos = 入营人数，neg = 未入营人数，总人数 $\mathrm{pos}+\mathrm{neg}$。
  难度 $D=\dfrac{\mathrm{neg}}{\mathrm{pos}+\mathrm{neg}}\in[0,1]$：没进营的人越多（$\mathrm{neg}$ 越大），D 越大。
- 对组内每条帖子，将其身上的竞赛标签、论文标签在全局上累加：
  进营（正向）：各标签 $+\dfrac{\mathrm{neg}}{\mathrm{pos}+\mathrm{neg}}$；　未进营（逆向）：各标签 $-\dfrac{\mathrm{pos}}{\mathrm{pos}+\mathrm{neg}}$。
- 所有标签的原始分累加后，在全局做一次归一化 0–100，得到 `comp_value.json`、`paper_value.json`、`tier_value.json`。
- 缺陷：某些高含金量的条目可能因全局累加的方式被低估。

权重计算代码

Listing 2: pos/neg 组内增量

```
# 按目标高校分组后: pos=入营人数, neg=未入营人数
for school, occs in school_occ.items():
    pos = sum(1 for x in occs if x["admitted"])
    neg = len(occs) - pos
    total = pos + neg
    if total <= 0:
        continue
    step_pos = neg / total   # 进营: + neg/(pos+neg)
    step_neg = pos / total   # 未进营: - pos/(pos+neg)

    for occ in occs:
        step = step_pos if occ["admitted"] else -step_neg
        for item in set(occ["comp_items"]):
            comp[item] += step
        for item in set(occ["paper_items"]):
            paper[item] += step
        tier[occ["tier_item"]] += step  # 本科层次, 同增量

# 全局 raw 再 normalize_to_100 -> comp_map, paper_map, tier_map
```

价值评估结果示例

表: 竞赛 / 论文 / 本科层次（归一化到 0–100，节选）

类型	价值	条目	价值
竞赛	100.0	世界超算大赛	99.28
竞赛	57.19	数学建模	57.19
竞赛	53.24	ACM	53.24
竞赛	0.0	蓝桥杯	0.0
论文	100.0	NeurIPS / CVPR	100.0
论文	94.04	CCF-B / SCI 二区	94.04
论文	12.77	WWW	12.77
论文	0.0	EI	0.0
本科层	100.0	末九	100.0
本科层	68.63	华五	68.63
本科层	0.0	其他	0.0

说明

此表为本批 114 条帖子在该规则下的统计结果示例，不代表真正价值。产物：`comp_value.json`、`paper_value.json`、`tier_value.json`。

按校建模：监督学习（二分类）

- 问题类型：每个「学院」对应一个独立的二分类问题。
- 特征 $\mathbf{x} \in \mathbb{R}^4$：本科层次、成绩、竞赛均分、论文均分。
- 标签 $y \in \{0, 1\}$：是否入营。
- 做法：在样本 $\{(\mathbf{x}_i, y_i)\}$ 上拟合判别模型；由拟合结果导出四维权重 $\mathbf{w}$，再算综合分 S。

数据流： 四维特征 $\longrightarrow$ 标准化 $\longrightarrow$ 拟合二分类模型 $\longrightarrow$ `school_bar.json`（`weights`、`Bar`、`acc` 等）

二分类：train_school.py

```python
from pathlib import Path
import json

def load_jl(p):
    return [json.loads(l) for l in open(p, encoding="utf-8") if l.strip()]

def main():
    r = Path("model/result")
    cb = {x["id"]: x for x in load_jl(r / "compact.jsonl")}
    vb = {x["id"]: x for x in load_jl(r / "vectors.jsonl")}
    voc = json.loads((r / "vocab.json").read_text(encoding="utf-8"))
    cv = json.loads((r / "comp_value.json").read_text(encoding="utf-8"))["values"]
    pv = json.loads((r / "paper_value.json").read_text(encoding="utf-8"))["values"]
    F = {i: row4(cb[i], vb[i], voc, cv, pv) for i in vb if i in cb}
    out = []
    for g in voc["school_dept_vocab"]:
        X, y = [], []
        for i in F:
            adm = cb[i].get("入营情况") or {}
            if g not in adm: continue
            X.append(F[i]); y.append(1 if adm[g] else 0)
        if not y: continue
        w, bar = train_one(X, y)
        out.append({"school_dept": g, "weights": w, "suggested_bar_score": bar})
    (r / "school_bar.json").write_text(
        json.dumps({"groups": out}, ensure_ascii=False, indent=2), encoding="utf-8")
```

综合分与权重来源

综合分（与 test.py 一致）

推理侧仍用与输入同顺序的四维：f_1 层次、f_2 成绩、f_3 竞赛均分、f_4 论文均分（与特征同源）。权重 $w_1, \ldots, w_4$（和为 1）：

$$S = w_1 f_1 + w_2 f_2 + w_3 f_3 + w_4 f_4$$

若 $S \geq$ suggested_bar_score，则判为「达到参考线」（S 为线性可解释分数，与模型内部概率标度不必同一尺度）。

权重从哪里来（与 train_school.py 对齐）

列标准化后逻辑斯蒂得到系数 β_j；第 j 列标准差记 σ_j，取重要性正比于 $|\beta_j|/\sigma_j$，归一化后与该校各维特征–标签相关系数按固定比例混合，再归一化得到最终 $\mathbf{w}$；样本极少时辅以先验与留一评估等。

产物展示：school_bar.json

同一批数据、不同「学院」权重与 Bar

上海交通大学-计算机　层次 9.3%，成绩 73.0%，竞赛 17.7%，论文 0%　Bar $\approx$ 75.58　acc 0.5　(n=4)
南京大学-计算机科学与技术　层次 50.3%，成绩 22.9%，竞赛 17.8%，论文 9.0%　Bar $\approx$ 55.72　acc 0.5　(n=4)
清华大学-计算机系　层次 0%，成绩 24.8%，竞赛 24.6%，论文 50.6%　Bar $\approx$ 29.43　acc 0　(n=2)
北京大学-计算机科学与技术　层次 32.4%，成绩 0%，竞赛 67.6%，论文 0%　Bar $\approx$ 47.51　acc 0　(n=2)

- 仅能说明在当前稀疏样本下拟合出的相对侧重；不能外推为各校官方招生标准。
- 输出：school_bar.json（weights、suggested_bar_score、acc、sample_pos/neg）。

用户画像

- 用户用自然语言描述自己在四个维度上的信息，参照上文的价值评估算出每一维度的分数。
- 对每一个学院：用该学院四维权重与用户的四维特征做加权和得到 S。
- 若 $S \geq$ 该校 suggested_bar_score，则标记为「预测过线」；同时可算 $S - \text{Bar}$ 作分差排序。

用户评分与院校门槛对比

```
for g in school_groups:
    w = g['weights']
    # 结合院校权重计算用户在该校的竞争力
    score = (w['院校层级'] * tier_f + w['成绩'] * rank_f +
             w['竞赛'] * comp_f + w['论文'] * paper_f)
    predict_admit = score >= g['suggested_bar_score']
```

输入示例：sample.json

```
{
    "院校层次": "华五",
    "成绩排名": "12/200",
    "竞赛获奖条目": [
      "ACM 区域银",
      "蓝桥杯 国一",
      "美赛 M奖"
    ],
    "论文条目": [
      "CCF-A",
      "SCI二区",
      "EI"
    ]
  }
```

推荐结果展示 I

命令：`python model/test.py --input-file sample.json`。


```
{
  "module_scores": {
    "tier_text": "华五",
    "院校层级分": 68.6317,
    "rank_text": "12/200",
    "成绩模块分": 94.5,
    "竞赛模块分": 34.2926,
    "论文模块分": 80.4255
  },
  "school_ranking": [
    {
      "school_dept": "上海交通大学-计算机",
      "total_score": 81.4451,
      "suggested_bar_score": 75.5755,
      "predict_admit": true,
      "bar_gap": 5.8696,
    },
    {
      "school_dept": "北京大学-计算机",
      "total_score": 74.7196,
      "suggested_bar_score": 15.013,
      "predict_admit": true,
      "bar_gap": 59.7066,
    },
    {
      "school_dept": "清华大学-计算机系",
      "total_score": 72.595,
      "suggested_bar_score": 29.4328,
      "predict_admit": true,
```

推荐结果展示 II


```
    "bar_gap": 43.1622,
  },
  {
    "school_dept": "西安交通大学-计算机",
    "total_score": 71.947,
    "suggested_bar_score": 25.5608,
```


字段含义：total_score 即加权和 S，suggested_bar_score 为 Bar，predict_admit 为 $S \geq$Bar；bar_gap 可排序；不应理解为入营概率。

竞赛、论文价值排行，节选）

论文价值

- NeurIPS / CVPR：100.0
- ccf-a 在投 / SCI-EI：≈ 99.15
- CCF-B / SCI 二区 / AAAI：≈ 94.04
- WWW：≈ 12.77　EI：0.0

竞赛价值

- 果酱（稀有标签）：100.0
- 世界超算大赛：99.28
- XCPC / 天梯：≈ 79.86
- 数模国赛 / 互联网 +：≈ 74–75
- 蓝桥杯 / 国奖 / CSP：≈ 0–20（本批数据下）

院校偏好差异

表: 四维权重（%）与 Bar；蓝色为该列相对最大

目标学校—院系	层次	成绩	竞赛	论文	Bar
上海交通大学-计算机	9.3	73.0	17.7	0.0	75.58
北京大学-计算机科学与技术	32.4	0.0	67.6	0.0	47.51
清华大学-计算机系	0.0	24.8	24.6	50.6	29.43
南京大学-计算机科学与技术	50.3	22.9	17.8	9.0	55.72
浙江大学-计算机科学与技术	6.2	25.9	25.5	42.4	58.36

- 校名以 JSON 中 `school_dept` 为准；北大「计算机」与「计算机科学与技术」为不同键。
- 结论仅适用于本批数据，可信度极低。